

Прогноз цены смартфонов на Авито

Содержание

- 1 Постановка задачи
- 2 Сбор и подготовка данных
- 3 Признаки
- 4 Модели
- 5 Результаты
- 6 Выводы

Цель и мотивация

Задача: по тексту и атрибутам объявления предсказать цену смартфона.

Зачем:

- оценка «рыночной» цены для покупателя/продавца;
- выявление аномально дорогих или дешёвых предложений;

Целевая переменная: цена объявления, руб.

Оценка ошибки: MAPE

Данные

- **Источник:** Авито, категория «Мобильные телефоны», Санкт-Петербург
- **Период:** последние 14 дней
- **Объём:** ≈ 7800 объявлений
- **Фильтр цен:** от 500 до 200 000 руб.

Данные были собраны с помощью парсера, который обходит страницы и сохраняет ключевые поля.

Ограничения выборки

Сильный перекос в сторону Samsung ($\sim 78\%$) и Apple ($\sim 14\%$). Модель в первую очередь описывает массовый сегмент рынка.

Парсинг Авито

Инструменты: Готовый парсер из открытых источников


Ключевые поля:

- Название
- Цена
- Описание
- Дата публикации
- Адрес (район)
- «Поднято» (используется ли платное продвижение)
- Изображения (кол-во фотографий)

EDA




Сильный перекос в сторону недорогих моделей, длинный хвост дорогих.



Доминируют Samsung и Apple, остальные бренды представлены слабо.

EDA




Примерно 20% объявлений с платным продвижением, они в среднем дороже.

Цены по брендам: Apple дороже, Samsung дешевле, остальные еще дешевле.

Feature engineering

Источник	Новые признаки
Из «Название»	brand, ram_gb, storage_gb, iphone_gen, флаги Pro/Max/Mini/Plus
Из «Описание»	has_warranty, has_box, has_charger, condition
Метаданные	is_promoted, photos_count, district, days_since_posted
Описание	title_only → TF-IDF (300–800 признаков)

Feature engineering




К признаку цены применено $\log(1 + y)$ для сглаживания хвоста и улучшения обучения моделей.


Итоговый набор признаков

Тип признака	Названия признаков
Численные (16 шт.)	ram_gb, storage_gb, iphone_gen, photos_count, title_len, description_len, days_since_posted, is_pro, is_max, is_mini, is_plus, is_promoted, has_warranty, has_trade_in, has_box, has_charger.
Категориальные (3 шт.)	brand, condition, district.
Текстовые	TF-IDF по title_only, 300–800 признаков.

EDA новых признаков





Наиболее популярные опции – 8 и 12 ГБ



Преобладают 128 и 256 ГБ


EDA новых признаков



Корреляций между числовыми признаками почти нет за исключением ram_gb и storage_gb, а также между флагом is_max.

TF-IDF

TF-IDF: топ-25 терминов



TF-IDF по названию позволяет выделить важные слова, связанные с ценой (например, «13 mini», «s10 128», «flip4 256»).

Сравниваемые модели

Модель	Комментарий
Dummy (mean)	baseline
Ridge	применяется StandardScaler
Decision Tree	ограничение 14 уровней
Random Forest	200 деревьев, 12 уровней
CatBoost	800 деревьев, depth 6, learning_rate 0.05
LightGBM	<1500 деревьев, num_leaves 31, subsample 0.85

Разделение выборки: 80% train, 20% test.

Метрики на всей тестовой выборке

Модель	MAPE	MAE, руб.	RMSE, руб.
Dummy	207%	17712	25450
Ridge	22.8%	3230	5452
Decision Tree	24.0%	2929	5833
Random Forest	25.1%	3187	5948
CatBoost	20.3%	2813	4717
LightGBM	9.1%	1213	2850

Лучшая модель: *LightGBM*

MAPE по сегментам тестовой выборки

Модель	Apple <i>n</i> =236	Samsung <i>n</i> =1191	Остальные <i>n</i> =132
Dummy	62.1%	227.1%	285.1%
Ridge	24.1%	20.0%	46.5%
Decision Tree	18.4%	18.9%	80.3%
Random Forest	21.5%	21.9%	59.9%
CatBoost	21.3%	16.6%	52.1%
LightGBM	14.7%	4.6%	39.3%

Практически все модели дают лучший результат на сегменте Samsung, так как данных по нему больше всего.

Метрики по сегментам: Apple и Samsung

Apple (iPhone), $n = 236$

Модель	MAPE	MAE, руб.	RMSE, руб.
Dummy	62.1%	26158	36160
Ridge	24.1%	4675	7320
Decision Tree	18.4%	4995	8461
Random Forest	21.5%	5577	9090
CatBoost	21.3%	4298	6773
LightGBM	14.7%	2873	5149

Samsung, $n = 1191$

Модель	MAPE	MAE, руб.	RMSE, руб.
Dummy	227.1%	16852	23833
Ridge	20.0%	2893	4853
Decision Tree	18.9%	2215	4448
Random Forest	21.9%	2523	4617
CatBoost	16.6%	2379	3833
LightGBM	4.6%	688	1413

Метрики по сегментам: остальные бренды


Остальные (не Apple и не Samsung), $n = 132$

Модель	MAPE	MAE, руб.	RMSE, руб.
Dummy	285.1%	10369	13683
Ridge	46.5%	3685	6541
Decision Tree	80.3%	5676	9766
Random Forest	59.9%	4907	8819
CatBoost	52.1%	4077	6944
LightGBM	39.3%	2984	5524


Мало примеров в test $\Rightarrow$ высокий разброс; деревья переобучаются сильнее бустинга.

Качество предсказаний

lightgbm: факт vs прогноз





Распределение |ошибки| / цена



Качество предсказаний

Детальный разбор ошибки — lightgbm



Пример объявления

Название: iPhone 15 Pro, 512 ГБ, SIM + eSIM

- **Бренд:** Apple
- **Память:** 512 ГБ
- **Описание:** В идеальном состоянии, носила только в чехлах, не падал, ничего не ломалось. Отдам 2 чехла. Без Торга, обмена на нокию с доплатой и прочего.
- **Цена (факт):** 52 000 руб.

CatBoost ближе всего к факту (ошибка 4.1%).

Модель	Прогноз	Ошибка	%
CatBoost	49 890	2 110	4.1%
LightGBM	55 831	3 831	7.4%
Random Forest	48 026	3 974	7.6%
Decision Tree	56 202	4 202	8.1%
Ridge	43 994	8 006	15.4%
Dummy	12 891	39 109	75.2%
Факт	52 000 руб.		

Выводы и ограничения

Выводы:

- собран датасет из 7793 объявлений;
- бустинг (CatBoost/LightGBM) превосходит линейные модели и dummy;
- TF-IDF названия и brand — ключевые сигналы цены.

Ограничения:

- дисбаланс брендов, низкое качество данных по менее популярным брендам;
- признак `iphone_gen` неинформативен вне Apple;
- парсинг усложняется из-за ограничений и блокировок со стороны Авито.

Улучшения: отдельные модели под каждый бренд, доработка сбора данных

Спасибо за внимание!